少量データの回帰で予測の不確かさまで示す(見本)

研究・高密度デザインシステムの見本デッキ
架空の合成データで作成。研究結果ではない

発表者 氏名
所属・学会名・発表日

本発表の要点

・n = 20 のテスト RMSE は GPR が最小(0.091)

・GPR の 95% 区間はテスト点の 100% を含む

・データが増えると手法間の差は縮む

主要文献

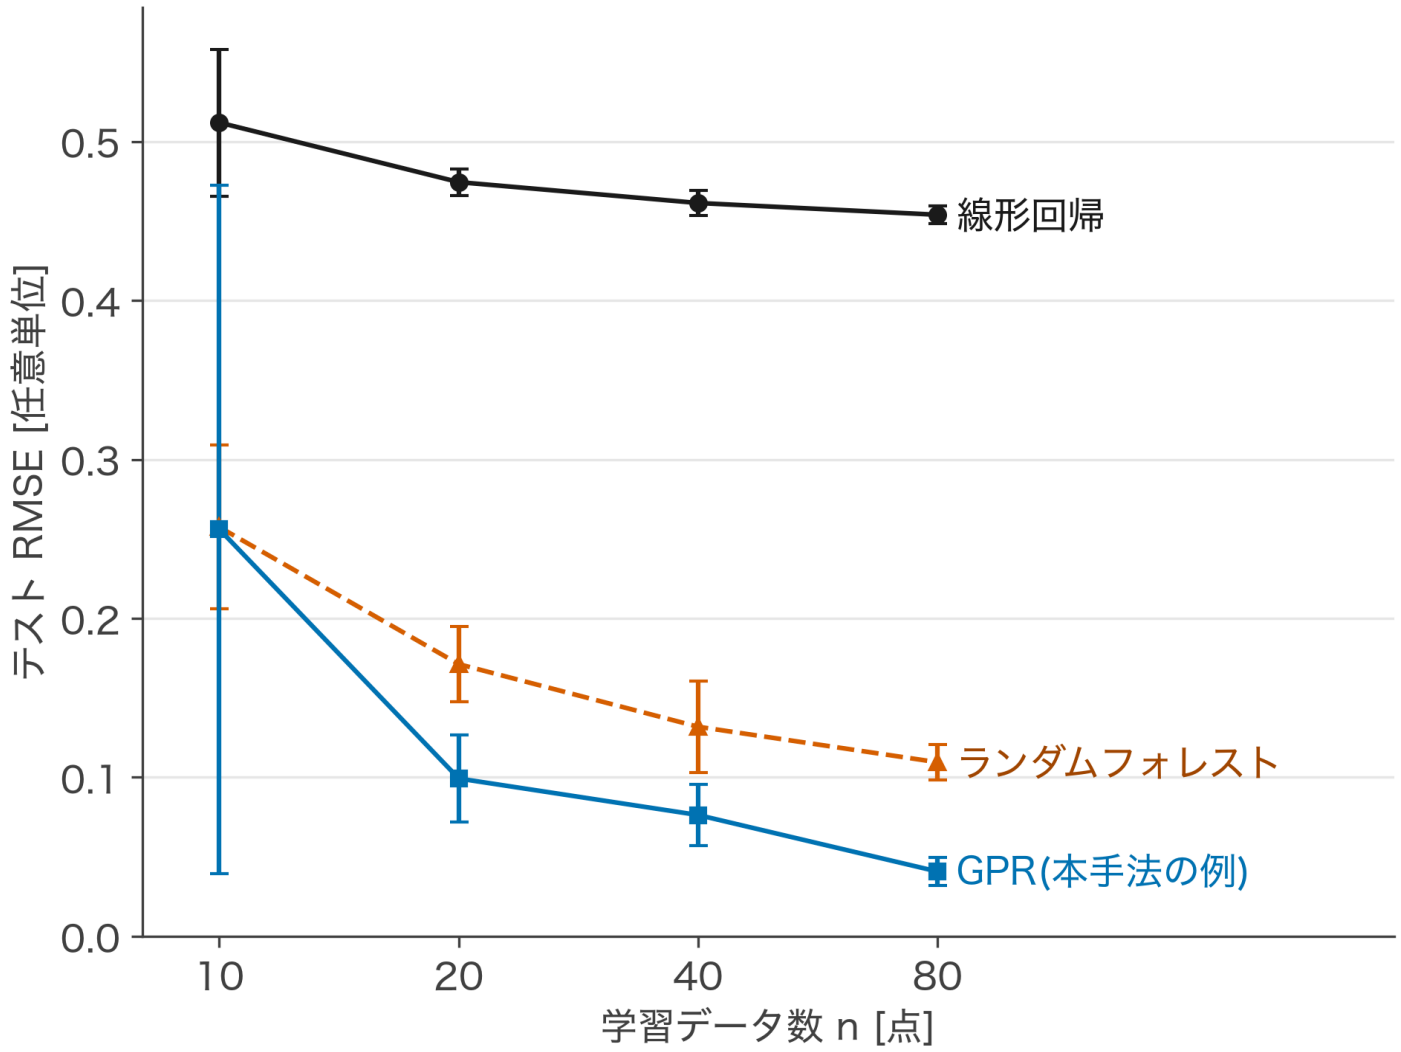
[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006.

[2] Breiman, L. Mach. Learn. 2001, 45, 5–32.

[3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

学習データが 20 点以下では GPR の RMSE が最も小さい(見本)

3 手法のテスト RMSE を学習データ数ごとに比べる。5 回の乱数で平均 ± 標準偏差



見本データ(合成関数)。研究結果ではない。誤差棒は ±1 σ (5 回)

RMSE(GPR, n = 20)

0.091

線形回帰は 0.490

95% 区間の被覆率

100%

テスト 200 点のうち区間内

・n = 10 では GPR の ばらつきが大きい (±1 σ)

・n が増えると RF と GPR の差は縮む

・線形回帰は n を増やしても下がらない(モデルの形が合わない)

条件	値
テスト点	200 点(等間隔)
乱数	5 回(seed 0–4)
観測雑音 σ	0.15

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006. [2] Breiman, L. Mach. Learn. 2001, 45, 5–32. [3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

GPR は予測の平均と分散を同時に返す

見本で使う手法の流れ・式・条件

データ生成 → **学習** → **予測** → **評価** → **比較**

合成関数+雑音
n = 10–80 点

3 手法を同じ
データで学習 [3]

テスト 200 点で
平均と分散

RMSE・MAE・R^2
95% 区間の被覆率

学習曲線と
パリティ図

$$\overline{f}_* = \mathbf{k}_*^\top (K + \sigma_n^2 I)^{-1} \mathbf{y} \tag{1}$$

$$\mathbb{V}[f_*] = k(\mathbf{x}_*, \mathbf{x}_*) - \mathbf{k}_*^\top (K + \sigma_n^2 I)^{-1} \mathbf{k}_* \tag{2}$$

式 (1)(2) は GPR の予測平均と予測分散 [1]。95% 区間は平均 ± 1.96 σ

記号	意味	単位
x*	予測したい点の記述子	任意
k*	学習点と x* の共分散	–
K	学習点どうしの共分散行列	–
σ_n^2	観測雑音の分散	任意²
y	学習データの目的変数	任意

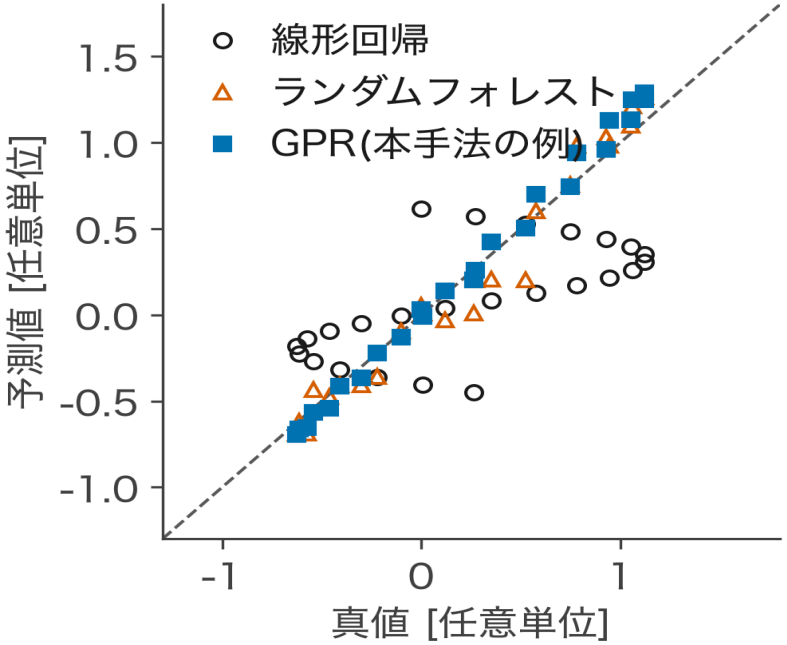
項目	設定
データ	$y = \sin(2\pi x) + 0.5x + \varepsilon$、$x \sim U(0, 1)$、$\varepsilon \sim N(0, 0.15^2)$
カーネル	定数 × RBF(初期長さ 0.2)+ 白色雑音。目的変数は正規化
比較手法	線形回帰、ランダムフォレスト(200 本)[2]
評価	テスト 200 点の RMSE・MAE・R^2、95% 区間の被覆率

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006. [2] Breiman, L. Mach. Learn. 2001, 45, 5–32. [3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

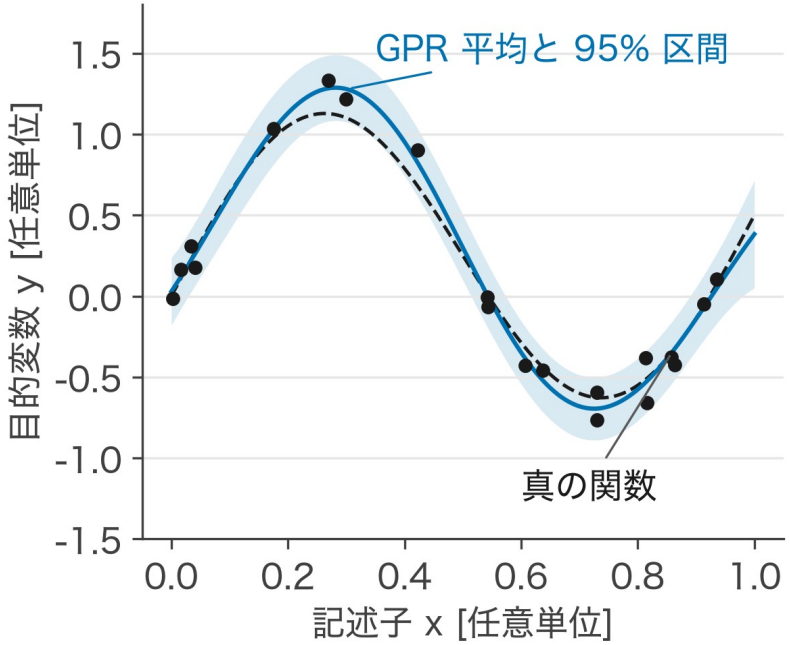
GPR は真の関数に沿い、学習点のない端で σ が大きくなる

n = 20、乱数 0 の代表例。(a)(b)(c) は同じ予測から作図

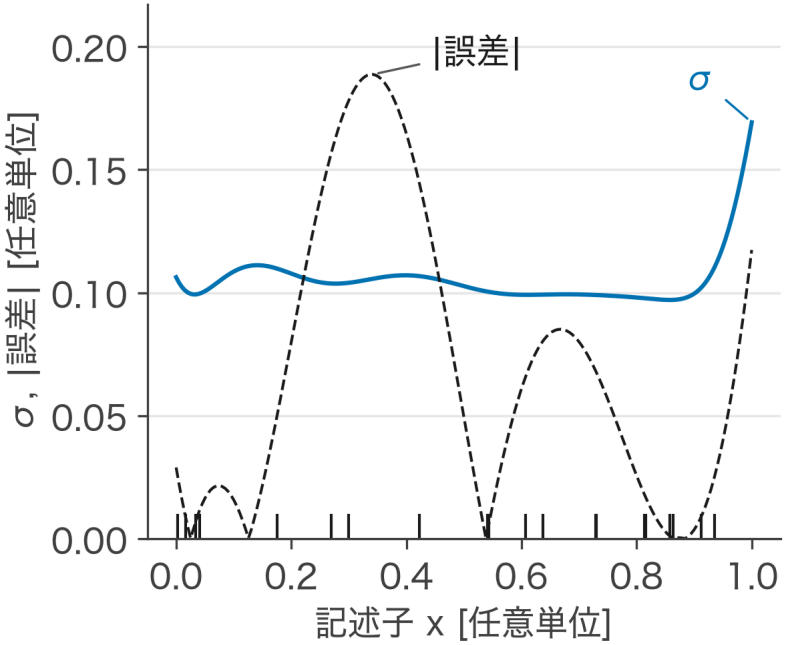
(a) 予測値と真値



(b) GPR の平均と 95% 区間



(c) GPR の σ と |誤差|



見本データ(合成関数)。研究結果ではない。破線は y = x(a)と真の関数(b)。(c) の下端の縦線は学習点の位置。帯は平均 ± 1.96 σ

手法	RMSE	MAE	R^2	不確かさ
線形回帰	0.490	0.424	0.33	なし
ランダムフォレスト	0.144	0.110	0.94	なし
GPR(本手法の例)	**0.091**	0.069	0.98	あり(式 2)

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006. [3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

データ数ごとの RMSE: 差は n = 10–20 で大きく、n = 80 で縮む

5 回の乱数の平均 ± 標準偏差。値が小さいほどよい

手法	n = 10	n = 20	n = 40	n = 80	n = 10 → 80
線形回帰	0.512 ± 0.046	0.474 ± 0.008	0.461 ± 0.008	0.454 ± 0.005	-11%
ランダムフォレスト	0.257 ± 0.052	0.171 ± 0.024	0.132 ± 0.029	0.109 ± 0.011	-57%
GPR(本手法の例)	0.256 ± 0.217	0.099 ± 0.027	0.076 ± 0.019	0.041 ± 0.009	-84%

見本データ(合成関数)。研究結果ではない。テスト RMSE [任意単位]。表は色なし・黒罫線

この表から言えること

・少量データでは GPR が最小

・線形回帰は n を増やしても改善しない

記号

・n: 学習データ数

・±: 5 回の標準偏差

関連文献

・GPR [1]、RF [2]

・実装 scikit-learn [3]

線形回帰

-11%

RMSE の変化(n = 10 → 80)

ランダムフォレスト

-57%

RMSE の変化(n = 10 → 80)

GPR(本手法の例)

-84%

RMSE の変化(n = 10 → 80)

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006. [2] Breiman, L. Mach. Learn. 2001, 45, 5–32. [3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

まとめ: 少量データでは予測の不確かさを一緒に示す

見本デッキの結論と限界

結論

・n = 20 で GPR の RMSE は 0.091、線形回帰の約 1/5(p.4)

・RF との差は n = 80 で縮む(p.5)

・95% 区間はテスト点の 100% を含む(p.2, p.4)

主要数値

RMSE(GPR, n = 20)

0.091

線形回帰 0.490

RMSE(RF, n = 20)

0.144

ランダムフォレスト

95% 区間の被覆率

100%

テスト 200 点

次の課題

・実データで同じ比較

・記述子を多次元に

限界

・1 次元の合成関数のみ

・ハイパーパラメータ探索なし

関連文献

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press, 2006.

[2] Breiman, L. Mach. Learn. 2001, 45, 5–32.

[3] Pedregosa, F. et al. J. Mach. Learn. Res. 2011, 12, 2825–2830.

色の設計: [4] Okabe, M.; Ito, K. J*Fly, 2002 (rev. 2008).

参考文献

本文の登場順。DOI と Web 資料の確認日つき

[1] Rasmussen, C. E.; Williams, C. K. I. Gaussian Processes for Machine Learning; MIT Press: Cambridge, MA, 2006. https://gaussianprocess.org/gpml/ (accessed 2026-10-20).

[2] Breiman, L. Random Forests. Mach. Learn. 2001, 45 (1), 5–32. https://doi.org/10.1023/A:1010933404324

[3] Pedregosa, F.; Varoquaux, G.; Gramfort, A.; et al. Scikit-learn: Machine Learning in Python. J. Mach. Learn. Res. 2011, 12, 2825–2830.

[4] Okabe, M.; Ito, K. Color Universal Design (CUD): How to Make Figures and Presentations That Are Friendly to Colorblind People. J*Fly, 2002 (rev. 2008). https://jfly.uni-koeln.de/color/ (accessed 2026-10-05).

[5] Wong, B. Points of View: Color Blindness. Nat. Methods 2011, 8 (6), 441. https://doi.org/10.1038/nmeth.1618

図表の出典

ページ	図表	区分
2	学習曲線	見本データ(本スクリプトで作成)
4	(a)(b)(c) と結果表	見本データ(本スクリプトで作成)
5	RMSE の表	見本データ(本スクリプトで作成)